



Gestion de projet & Produit digital

M2 SEP Année universitaire 2025-2026

FPI : FRANCE PROPERTY INSIGHT

Réalisé par :

Daniel **PHAN**
Nicolas **COLLIN**
Kim Ngan **THAI**
Perle **NDAYIZEYE**
Claudy **LINCY**

Sous la direction de :

Morgan **COUSIN**
Amor **KEZIOU**

Table des matières

Table des matières.....	2
Table des figures.....	3
Table des tableaux.....	3
Remerciements.....	4
Résumé.....	5
Contexte.....	6
Contexte.....	8
Présentation des données.....	10
L'origine des données.....	10
Le périmètre géographique.....	11
La mise à jour des données.....	11
Dictionnaire des variables.....	12
Présentation de l'application.....	13
Fonctionnalités principales.....	13
Installation.....	14
Interface utilisateur.....	14
Aparté sur l'installation du produit.....	19
Flux des données.....	24
Nettoyage et préparation des données (NA, dups, outliers).....	25
Variables non retenues et raisons de rejet :.....	28
Analyse des données.....	30
Modélisation et prédictions.....	32
Sélection ou transformation des variables.....	32
Description des modèles utilisés.....	34
Méthodes d'évaluation et résultats.....	35
Tableau 1 - Comparaison des performances des modèles Ridge/Lasso/Random Forest.....	35
Modèle retenu — Version 1.....	37
Limites et axes d'amélioration.....	37
Ajout de nouveaux modèles : Gradient Boosting et Decision Tree.....	38
Tableau 2 - Comparaison des modèles Gradient Boosting et Decision Tree...	39
Déroulement des sprints.....	41
Sprint 1.....	41
Sprint 2.....	42
Sprint 3.....	43
Environnement de développement et choix techniques.....	52
Conclusion.....	52
Bibliographie / Références / Liens.....	53
Annexes.....	54

Table des figures

Figure 1 - Plus de 900 000 ventes de logements anciens sur les 12 derniers mois.....	8
Figure 2 - Logigramme de FPI.....	13
Figure 3 - page d'accueil.....	14
Figure 4 - page du tableau de bord (Overview).....	16
Figure 5 - page Explore the market.....	17
Figure 6 - page de prédiction.....	18
Figure 7 - page de prédiction.....	18
Figure 8 - dataflow.....	24
Figure 9 - évolution des prix immobiliers en Île-de-France.....	31
Figure 10 - Random forest sur les variables.....	36

Table des tableaux

-

Remerciements

Ce projet n'aurait pas été possible sans l'encadrement prodigué par le Master SEP : Statistique pour l'Évaluation et la Prévision de l'Université de Reims Champagne-Ardenne.

Nous remercions nos professeurs et les responsables du Master Emmanuelle GAUTHERAT, Jules MAES, et Philippe REGNAULT; mais en particulier Morgan COUSIN, responsable du module Gestion de Projet/Produit Digital et Amor KEZIOU pour ses enseignements, conseils et avis autour du Machine Learning.

Résumé

France Property Insight (FPI) est un produit d'analyses statistiques et de prédictions sur les **transactions immobilières en France**. Il permettrait aux **futurs acheteurs** d'estimer le budget nécessaire à leurs projets ou aux **propriétaires** de jauger la valeur de leurs biens sur plusieurs années.

Le produit sera développé sur cinq sprints de deux semaines, chacun donnant lieu à un rapport, un livrable fonctionnel et une démonstration auprès de Monsieur Morgan COUSIN, responsable du module Gestion de Projet Digitaux dans le cadre du Master 2 SEP : Statistique pour l'Évaluation et la Prévision.


Nos modèles reposent sur le Machine Learning et s'appuient sur le cours d'Apprentissage Supervisé de Monsieur Amor KEZIOU, Maître de conférences à l'Université de Reims Champagne-Ardenne.

Le jeu de données « Demandes de valeurs foncières », publié et produit par la Direction Générale des Finances Publiques (DGFP), permet de connaître les transactions immobilières intervenues au cours des cinq dernières années sur le territoire métropolitain et les DOM-TOM, à l'exception de l'Alsace, de la Moselle et de Mayotte. Les informations proviennent des actes notariés et des données cadastrales.

Contexte

Dans le contexte actuel du marché immobilier français, **particuliers et investisseurs** sont confrontés à un défi difficile : déterminer le bon moment pour acheter ou vendre un bien, ainsi que son prix réaliste.

Figure 1 - Plus de 900 000 ventes de logements anciens sur les 12 derniers mois



Source : <https://edito.meilleursagents.com>

Après la détente monétaire amorcée dès 2024, beaucoup espéraient un redémarrage net de l'activité immobilière. Si le rebond a bien eu lieu en début d'année, il n'a pas tenu ses promesses sur la durée. Néanmoins, le nombre de transactions reste conséquent et l'État souhaite le voir remonter afin de retrouver les niveaux d'avant-crise.

Au-delà de la politique monétaire, plusieurs facteurs économiques et structurels influencent le marché en 2025. L'inflation, bien que sous contrôle ces derniers mois, reste un enjeu : par exemple, la Banque de France prévoyait un taux autour de 1 % pour 2025.

Les conditions de crédit se sont nettement améliorées : les taux moyens des prêts immobiliers s'établissaient à environ 3,24 % sur 20 ans et 3,32 % sur 25 ans début 2025.

Certaines expertises anticipaient même des taux pouvant descendre sous la barre des 3 % pour les meilleurs profils.

Pour mars 2025, le taux moyen national était autour de 3,45 % selon les régions. Cette amélioration de l'accès au crédit, combinée à une production de prêts en forte croissance (+50 % ou plus sur certains mois).

Parallèlement, les normes environnementales et la fiscalité modifient les comportements : l'obligation de rénovation pour certains logements, les dispositifs incitatifs ou restrictifs, participent à orienter les choix vers des biens mieux isolés ou adaptés aux nouveaux usages. Les dynamiques démographiques et sociétales entrent aussi en jeu : télétravail, mobilité accrue, souhait de logements plus spacieux (surtout en périphérie) transforment la demande.

Enfin, la géographie reste un facteur clé : les grandes métropoles continuent de connaître une forte pression prix et une demande soutenue, tandis que certaines zones rurales ou moyennes montrent des signes de stabilisation, voire de légère baisse des volumes et des prix. Dans ce contexte très segmenté, l'analyse locale et fine s'impose pour optimiser les décisions d'achat, de vente ou d'investissement.

FPI (France Property Insight) répond à ce besoin en proposant un outil analytique et prédictif des transactions immobilières. Il permet aux utilisateurs de visualiser les tendances du marché, d'estimer la valeur probable d'un bien selon ses caractéristiques et sa localisation, et d'identifier les zones ou types de biens les plus pertinents selon leurs objectifs. Dans un marché encore dynamique mais incertain, disposer de données fiables et d'analyses fines devient un atout stratégique pour orienter les décisions, limiter les risques et anticiper les évolutions futures, que ce soit pour un investissement locatif, l'acquisition d'une résidence principale ou la revente d'un patrimoine immobilier.

Source : <https://edito.meilleursagents.com>

Présentation des données

Le jeu de données « **Demandes de valeurs foncières** », publié et produit par la Direction Générale des Finances Publiques (DGFIP), permet de connaître les transactions immobilières intervenues au cours des cinq dernières années sur le territoire métropolitain et les DOM-TOM, à l'exception de l'Alsace, de la Moselle et de Mayotte.

Les données contenues sont issues des actes notariés et des informations cadastrales.

Lien vers le jeu de données :

<https://www.data.gouv.fr/datasets/demandes-de-valeurs-foncieres/>

L'origine des données

Les informations mises à disposition sont issues du traitement informatisé « Demande de valeurs foncières » alimenté par la « **Base nationale des données patrimoniales** » (BNDP).

L'application BNDP, qui recense les données patrimoniales contenues dans les documents déposés par les redevables ou leurs représentants dans les services en charge de la publicité foncière et de l'enregistrement, est alimentée par les traitements informatisés de l'administration fiscale relatifs à la documentation cadastrale (traitement « Majic ») et à la publicité foncière (traitement « Fidji »).

Les informations figurant dans chaque fichier sont donc **issues du système d'information de la DGFIP** (Direction Générale des Finances Publiques), après publication des actes par le service de la publicité foncière, et complément des éléments cadastraux (référence cadastrale, nature des biens et descriptif des biens).

Important : le descriptif des biens de l'acte notarié n'est pas repris dans le fichier, à l'exception de la surface Carrez lorsque celle-ci est mentionnée.

NB : le contenu des fichiers dépend donc des informations qui auront été dûment publiées par le service de la publicité foncière.

Le périmètre géographique

Les informations diffusées sont issues des mutations publiées dans les services de la publicité foncière de **l'ensemble du territoire de la France métropolitaine, à l'exception des départements du Bas-Rhin, du Haut-Rhin et de Moselle**; les données les concernant relèvent du « livre foncier » et ne sont pas mobilisées dans la base nationale des documents patrimoniaux (BNDP), ainsi que des départements et régions d'outre-mer, excepté Mayotte.

La mise à jour des données

En application du décret du 28 décembre 2018, les informations communiquées font l'objet d'une mise à jour semestrielle.

Chaque année, une première diffusion sera effectuée en avril, présentant les mutations intervenues au cours des cinq dernières années et ayant fait l'objet d'une publication par un service de publicité foncière avant le 31 décembre de l'année précédente. La diffusion du mois d'avril concerne en conséquence cinq millésimes soit 10 semestres. Une seconde diffusion sera effectuée en octobre portant sur les mutations intervenues au cours des cinq dernières années et ayant fait l'objet d'une publication par un service de publicité foncière avant le 30 juin de l'année en cours.

L'attention est appelée sur le fait qu'en avril comme en octobre, compte tenu des publications effectuées au cours du dernier semestre pouvant porter sur des mutations intervenues lors de semestres précédents, l'ensemble des fichiers annuels sont actualisés.

Chaque mise à jour supprime puis remplace la totalité des fichiers précédemment publiés.

La dernière mise à jour date du 6 avril 2025.

Dictionnaire des variables


Le jeu de données brut propose 43 variables, cependant nous allons retenir les quelques variables suivantes (voir les raisons de rejets ici : [Variables non retenues et raisons de rejet :](#))

Libellé originel	Descriptif	Nouveau nom dans notre base de données
Valeur foncière	Montant de l'évaluation déclaré(e) dans le cadre d'une mutation à titre onéreux. Inclut : frais d'agence si à charge du vendeur et TVA Exclut : frais d'agence si à charge de l'acquéreur, frais de notaires, valeur des biens meubles stipulée dans l'acte de mutation	property_value
Date de mutation	Format JJ/MM/AAAA	transaction_date
Nature de la mutation	Vente, vente en l'état futur d'achèvement, vente de terrain à bâtir, adjudication, expropriation ou échange	transaction_type
Code postal	Référence cadastrale de la parcelle.	postal_code
Code département	Référence cadastrale de la parcelle.	department_code
Code commune	Référence cadastrale de la parcelle.	town_code
Commune	-	town
Code type local	1 : maison, 2 : appartement, 3 : dépendance (isolée), 4 : local industriel et commercial ou assimilés	property_type_code
Type local	-	property_type
Surface réelle bâtie	La surface réelle est la surface mesurée au sol entre les murs ou séparations et arrondie au mètre carré inférieur. Les surfaces des dépendances ne sont pas prises en compte.	building_area
Nombre pièces principales	Les cuisines, salles d'eau et dépendances ne sont pas prises en compte.	main_rooms
Surface terrain	Contenance du terrain	land_area

Présentation de l'application

Fonctionnalités principales

Figure 2 - Logigramme de FPI



Source : les auteurs, 2025

Logigramme de l'application FPI

Nos objectifs fonctionnels se résument donc en 2 fonctionnalités :

- Tableau de bord ou visualisation des données (évolution du prix et des ventes, distribution des prix, prix médian du m²...)
- Prédiction de la valeur foncière d'un bien en fonction des saisies d'informations utilisateurs (nombre de pièces, surface, localisation...) et la simulation de financement.

Installation

L'utilisateur peut accéder à l'application directement depuis son navigateur via le lien suivant : <https://gpd-m2sep-france-property-insight.onrender.com/>


Il a également la possibilité d'installer nos fichiers sources pour exécuter l'application en local, sans connexion Internet (voir notre [documentation](#) pour plus de détails).

Interface utilisateur

L'application, développée avec [Gradio](#), est conçue pour être simple, intuitive et interactive. Elle se compose de **trois pages principales** : *Accueil*, *Dashboard* et *Prédiction*.

1. Page d'accueil

Figure 3 - page d'accueil



Source : FPI, 2025

Cette page constitue le point d'entrée vers les principales fonctionnalités de l'application : le tableau de bord, l'outil de prédiction, ainsi que l'accès à la documentation (API Docs) et au dépôt GitLab du projet.

Voici un aperçu de la documentation.

<https://france-property-insight-docs.onrender.com/fpi.html>



Search...

Contents

[Features](#)

[Submodules](#)

[Functions definitions](#)

API Documentation

[plot_sales_count_by_department\(\)](#)

[plot_price_evolution_by_department\(\)](#)

[get_location_choices\(\)](#)

[filter_data_by_location\(\)](#)

[calculate_market_metrics\(\)](#)

[create_sales_by_property_type_plot\(\)](#)

[get_sales_by_type_data\(\)](#)

[calculate_financing_simulation\(\)](#)

[compare_departments\(\)](#)

[display_trend\(\)](#)

[summary\(\)](#)

[compute_descriptive_statistics\(\)](#)

fpi.analysis

Analysis subpackage of the FPI application.

This subpackage contains all analytical tools used across the project.

Features

- Statistical summaries
- Descriptive statistics
- Visualizations for dashboards
- Historical trend plots
- Price computation utilities
- A full exploratory data analysis pipeline

Submodules

plots

Low-level plotting utilities based on Matplotlib and Seaborn.

- [display_trend](#) : saves price evolution plots (region and department)
- Helper functions for cleaning and formatting values

dashboard

Plot-building utilities designed for the Gradio dashboard interface.

- [plot_sales_count_by_department](#)
- [plot_price_evolution_by_department](#)

stats

Statistical helpers for inspecting and understanding datasets.


- [summary](#) : quick printed overview
- [compute_descriptive_statistics](#) : formatted statistics and CSV exports
- [get_summary_data](#) : metadata extractor for tests

Notre documentation explique le comportement et le rôle des sous parties de notre code mais aussi des fonctions individuelles. Nous y avons porté une attention particulière pour faciliter l'éventuelle reprise de notre travail par d'autres développeurs.

2. Page du Dashboard

a. Tab Overview

Figure 4 - page du tableau de bord (Overview)




Source : FPI, 2025

Le tableau de bord offre une vue d'ensemble de la base de données (*data overview*) ainsi que des statistiques descriptives. L'utilisateur peut interagir avec les visualisations pour explorer les données selon différents critères et mieux comprendre les tendances du marché immobilier.

b. Tab Explore the market

Figure 5 - page Explore the market



Source : FPI, 2025

L'utilisateur peut sélectionner une zone à explorer depuis une liste déroulante. La page affiche ensuite les principaux indicateurs de marché, tels que le nombre de biens vendus ou le prix médian au mètre carré selon le type de bien. Des graphiques interactifs présentent également la répartition des ventes par type de bien et par année, permettant à l'utilisateur d'explorer les données en détail.

3. Page Prédiction

Figure 6 - page de prédiction

Estimate the property value

Enter the characteristics of the property to get an estimated price.

Postal code: 77120 - MOURoux

Property type: Appartement

Living area (m²): 80

Number of rooms: 2

Land area (m²): 90

Estimate **Reset**

Estimated property price: €1,277,185

Source : FPI, 2025

Cette page permet à l'utilisateur d'effectuer des prédictions personnalisées à partir de variables qu'il peut saisir et sélectionner, le résultat est généré instantanément.

Financing simulation

Figure 7 - page de prédiction

Financing simulation

Loan parameters

Property price (€): 200000

Personal contribution (€): 40000

Loan duration (years): 20

Interest rate (%): 2,5

Calculate

Simulation results

Monthly payment (€): 847,84

Total loan cost (€): 203482,71

Debt ratio (%): 28,26

Source : FPI, 2025

L'utilisateur peut également effectuer une simulation de crédit en indiquant le montant souhaité, son apport personnel, ainsi que la durée et le taux d'intérêt. L'outil calcule ensuite le montant des mensualités, le coût total du crédit et le ratio d'endettement.

Aparté sur l'installation du produit

Dès le début du projet, nous nous sommes posé une question : comment simplifier au maximum l'installation et la prise en main pour l'utilisateur ?

Au début, nous avons imaginé plusieurs façons de faire, par exemple créer un **fichier exécutable** capable d'installer automatiquement tous les prérequis nécessaires à l'application. Mais très vite, nous nous sommes rendu compte que ce n'était pas la solution la plus simple, surtout pour un projet collaboratif.

Initialement, le livrable demandait à l'utilisateur de suivre les mêmes procédures d'installation que nos développeurs, c'est-à-dire : **Git + Python + uv**.

L'utilisateur devait cloner le projet, installer Python, puis synchroniser les dépendances avec uv. Cette méthode fonctionnait bien en local, mais elle restait longue et parfois source d'erreurs, surtout sur les différents systèmes d'exploitation.

Ensuite, nous avons cherché à simplifier avec **Docker**, qui permet de regrouper Python, uv et toutes les dépendances dans une seule image et même d'imposer un système d'exploitation unique.

C'était déjà une belle avancée, car plus besoin d'installer manuellement quoi que ce soit : il suffisait de lancer une seule commande `docker` pour installer et lancer l'application.

Cependant, Docker restait encore une étape technique : il fallait l'installer, comprendre les commandes, et cela ne rendait pas l'application "instantanée" à utiliser, l'installation en devenait même plus longue.

C'est là qu'est venue notre idée : rendre le projet disponible directement sur internet, accessible depuis n'importe quel navigateur, sans aucune installation.

Pour ça, il a fallu comprendre comment héberger une application python en ligne, et surtout quelles solutions étaient possibles : Render, HuggingFace, GitHub Pages, ou encore des serveurs personnels.

Chaque méthode avait ses particularités :

- **GitHub Pages** est parfait pour les sites statiques (HTML, CSS, JavaScript), mais ne permet pas d'exécuter une application Python
- **HuggingFace** est pensé pour les projets d'intelligence artificielle, souvent basé sur Streamlit ou Gradio, mais plus limité pour des frameworks comme FastAPI ou NiceGUI.
- **Les serveurs personnels** offrent une liberté totale, mais demandent une configuration lourde : nom de domaine, pare-feu, gestion du SSL, redémarrage automatique du service, etc.
- **Render**, en revanche, propose une solution très complète et surtout automatique, il suffit de connecter le dépôt GitLab, et le déploiement se fait tout seul : installation des dépendances, exécution du script principale, et hébergement sur une URL publique.

Après finalement un choix porté pour **Render**, nous avons pu concrétiser la mise en ligne de notre application. L'idée était simple : automatiser au maximum le déploiement tout en gardant notre organisation initiale sur GitLab.

Pour cela nous avons mis en place un dépôt miroir entre GitLab et GitHub.

Ce dépôt miroir permet de répliquer automatiquement chaque mise à jour du projet GitLab vers GitHub, afin que Render puisse accéder au code sans contrainte.

De cette façon, à chaque nouveau push la branche principale du projet (main dans notre cas), Render détecte automatiquement le changement et relance le déploiement du site.

Une fois la connexion établie, il a fallu paramétrer correctement Render.

Nous avons d'abord précisé le chemin du script principal (dans notre [main.py](#)) puis la commande de lancement (`uv run main`) afin que Render sache comment exécuter l'application.

Nous avons également configuré les variables d'environnement, et vérifié que le fichier `pyproject.toml` contenait bien toutes les dépendances nécessaires au projet.

A partir de là, Render s'occupe de tout : il crée un environnement isolé, installe les librairies, construit le projet et le déploie automatiquement sur une URL publique.

Ce système est très pratique, car il ne nécessite plus aucune intervention manuelle de notre part : à chaque fois que le projet est mis à jour, le site se met automatiquement à jour lui aussi. Mais comme souvent, tout n'a pas été parfait dès le départ.

Nous avons rencontré quelques problèmes techniques au cours de la mise en ligne.

D'abord , le temps de build était parfois long : render réinstalle toutes les applications à chaque déploiement, ce qui pouvait prendre plusieurs minutes, et surtout lorsque certaines librairies (comme pydantic ou FastAPI) nécessitent une compilation. Nous avons dû adapter nos fichiers de configuration pour accélérer le processus, notamment en allégeant les dépendances inutiles.

Ensuite , il y a eu la gestion des ports : par défaut, Render attribue un port dynamique, ce qui oblige à bien configurer les serveurs python pour qu'il s'adapte automatiquement au port fourni.

Une simple erreur dans cette configuration empêchait parfois le site de démarrer, ce qui à nécessité plusieurs ajustements avant d'obtenir un déploiement stable.

Mais le principal inconvénient est venu du comportement de Render vis-à-vis de l'inactivité. Lorsqu'un site n'est pas utilisé pendant un certain temps (15 minutes), Render le met en veille automatiquement. Le problème, c'est que lorsqu'un utilisateur tente d'accéder au site après une période d'inactivité, le service doit redémarrer complètement, ce qui peut prendre entre 1 et 3 minutes.

En se mettant à la place de l'utilisateur, c'est loin d'être idéal : on s'attend à ce que le site réponde immédiatement, et cette attente donne l'impression que l'application ne fonctionne pas ou qu'elle est lente.

Pour palier à ce problème, deux solutions s'offrent à nous. La première est de souscrire à l'offre payante de Render, ce qui pour nous est complètement impensable. Et la deuxième après beaucoup de réflexion, nous avons décidé de mettre en place un système de ping régulier. Celui-ci envoie automatiquement une requête vers le site à intervalles réguliers, empêchant Render de le mettre en veille. Grâce à cette astuce, le serveur reste éveillé en permanence, ce qui garantit un temps de chargement quasi instantané pour les utilisateurs. Nous avons donc rendu le payant, gratuit !

En résumé, Render s'est montré comme la meilleure solution pour notre projet : simple à configurer , compatible avec python et nos outils, et surtout entièrement automatisé grâce à la synchronisation GitLab-GitHub. Malgré quelques contraintes techniques comme le temps de build et la veille automatique, nous avons réussi à obtenir un site stable, fluide et accessible à tout instant, sans aucune installation au préalable.

FastAPI

Pour améliorer la structure de notre application et séparer l'interface Gradio du backend, nous avons opté pour FastAPI. Notre objectif était de créer une API robuste capable de recevoir les données du formulaire, de les valider avec Pydantic, et de renvoyer une prédiction au format JSON. La mise en place s'est avérée plus complexe que prévu, plusieurs problèmes survenant au fil du temps. Nous avons dû ajuster certaines parties...

Nous avons commencé par comprendre le fonctionnement de Pydantic. Nous avons constaté qu'il sert de schéma de validation utilisé par la route POST/predict. Cette route nous permet d'utiliser efficacement Pydantic pour valider nos données. Une route a été créée entre le formulaire et la prédiction pour passer par Pydantic et garantir une structure cohérente avec notre prédiction. L'un des premiers problèmes rencontrés était précisément lié à cette validation. Si un champ était manquant ou mal typé, FastAPI renvoyait automatiquement une erreur 422. Bien que cette erreur soit attendue, elle apparaissait initialement même lorsque les données semblaient correctes. Après plusieurs essais, nous avons découvert que certains champs étaient encore envoyés en chaîne de caractères alors que Pydantic attendait des floats ou des ints. Nous avons donc harmonisé les types et ajouté des conversions explicites dans Gradio et dans les validateurs Pydantic.

Un autre problème rencontré concerne la gestion des erreurs dans l'API. Initialement, nous utilisions un except global, une pratique généralement déconseillée, car elle masque la nature des erreurs et complique le débogage. Pour y remédier, nous avons mis en place un traitement d'exception plus précis : les ValueError renvoient un statut 400, les FileNotFoundError un statut 500, tandis que toutes les autres erreurs sont gérées par un message centralisé. Cette amélioration facilite grandement la résolution des bugs et des problèmes liés au modèle.

Un autre défi majeur a été la gestion des données à l'entrée et à la sortie de la route FastAPI. Nous avons remarqué des incohérences entre les variables envoyées par Gradio et celles attendues par l'API. Par exemple, certains champs étaient transmis sous forme de chaîne de caractères alors que l'API s'attendait à des entiers numériques. De plus, les noms de variables ne correspondaient pas toujours entre le formulaire, le schéma Pydantic et les données transmises au modèle de prédiction.


En plus de toutes ces erreurs, la structure renvoyée par FastAPI devait répondre parfaitement au `response_model` défini dans la route, sinon l'API renvoie des erreurs de validation en sortie. Nous avons donc aligné les noms des champs, normalisé les types et vérifié que la sortie respectait bien la forme définie par le `PredictionResponse`. Cette étape est importante pour garantir le bon fonctionnement de la route : entrée utilisateur → validation → prédiction → réponse JSON.

Donc, après beaucoup de problèmes, on peut dire que FastAPI est vraiment un outil, malgré la complexité de la chose...

La séparation interface/backend est désormais nette, les données sont validées et nettoyées automatiquement grâce à Pydantic mis en place dans le sprint précédent et en fait donc une force ! Cela rend quand même notre système plus fiable.

Flux des données

Figure 8 - dataflow



Source : les auteurs, 2025

Nous prévoyons une **architecture de données en médailles** (Bronze/Argent/Or) ou données brutes/nettoyées/préparées (=prêtes pour analyse/modélisation).

Du côté utilisateur, ses requêtes seront envoyées sous forme de payload JSON, transmises à travers une API web développée avec FastAPI, puis validées par Pydantic avant d'être traitées par la couche applicative. Cette couche calculatoire accèdera aux données via SQLAlchemy, afin de faciliter la **portabilité entre différents systèmes de gestion de base de données** tels que SQLite, MySQL ou PostgreSQL.

Nettoyage et préparation des données (NA, dups, outliers)

Concernant la préparation des données, nous avons créé une fonction qui fusionne les tables en .txt, elle extrait ensuite les variables intéressantes à explorer et enrichir notre produit, tout en renommant ces dernières. Après avoir choisi les variables qui nous intéressent, nous supprimons les NA et les doublons ainsi que les valeurs aberrantes.

Les données complètes sur toute la France étant trop lourdes pour GitLab, nous avons décidé de se concentrer temporairement sur la région d'Île de France, elle comprend 8 départements : Paris (75), Seine-et-Marne (77), Yvelines (78), Essonne (91), Hauts-de-Seine (92), Seine-Saint-Denis (93), Val-de-Marne (94) et Val-d'Oise (95). Nous avons appliqué un filtre afin de ne garder que les transactions dans les départements de la région en utilisant la variable "department_code" (=code département).

Toutes les fonctionnalités de FPI seront toutefois scalables sur les données de toute la France, tant que l'utilisateur est prêt à télécharger localement toutes les données.

Effectif des variables manquantes

Variable	Value
Identifiant_de_document	1979256
Reference_document	1979256
1_Articles_CGI	1979256
2_Articles_CGI	1979256
3_Articles_CGI	1979256
4_Articles_CGI	1979256
5_Articles_CGI	1979256
No_disposition	0
Date_mutation	0
Nature_mutation	0
Valeur_fonciere	16722
No_voie	252995
B/T/Q	1863417
Type_de_voie	197191
Code_voie	30670
Voie	30730
Code_postal	30694
Commune	0
Code_departement	0
Code_commune	0
Prefixe_de_section	1971282
Section	0
No_plan	0
No_Volume	1971133
1er_lot	661458
Surface_Carrez_du_1er_lot	1540861
2eme_lot	1529381
Surface_Carrez_du_2eme_lot	1847356
3eme_lot	1916420
Surface_Carrez_du_3eme_lot	1967306
4eme_lot	1957490
Surface_Carrez_du_4eme_lot	1976372
5eme_lot	1970109
Surface_Carrez_du_5eme_lot	1978256
Nombre_de_lots	0
Code_type_local	336625
Type_local	336625
Identifiant_local	1979256
Surface_reelle_bati	337530
Nombre_pieces_principales	337530
Nature_culture	1326517
Nature_culture_speciale	1917987
Surface_terrain	1326517

Effectif des outliers

Variable	Value
Identifiant_de_document	0
Reference_document	0
1_Articles_CGI	0
2_Articles_CGI	0
3_Articles_CGI	0
4_Articles_CGI	0
5_Articles_CGI	0
No_disposition	50776
Valeur_fonciere	282163
Code_departement	0
Code_commune	27236
No_plan	158528
Surface_Carrez_du_1er_lot	16376
Surface_Carrez_du_2eme_lot	4417
Surface_Carrez_du_3eme_lot	699
Surface_Carrez_du_4eme_lot	209
Surface_Carrez_du_5eme_lot	78
Nombre_de_lots	62836
Identifiant_local	0

Effectif du type de propriété

Variable	Value
Dépendance	788203
Appartement	557081
nan	336625
Maison	210842
Local industriel, commercial ou assimilé	86505

Variables non retenues et raisons de rejet :

Libellé	Raison de rejet
Code service CH	Non restitué
Référence document	Non restitué
Article CGI 1-5	Non restitué
N° de voie/B/T/Q	Valeurs manquantes
Type de voie/Code voie/Voie	Valeurs manquantes
Préfixe de section/Section	Valeurs manquantes
N° de plan/N° de volume	Valeurs manquantes
1er-5ème lot	Valeurs manquantes
Surface Carrez du 1er-5ème lot	Valeurs manquantes
Identifiant local	Non restitué
Code nature culture	Valeurs manquantes
Nature culture spéciale	Valeurs manquantes

Validation des données

Après avoir structuré notre base de données, nous avons voulu aller plus loin en vérifiant la fiabilité des informations qu'elle contient. Pour cela, nous avons intégré **Pydantic**, un outil de validation python qui nous permet de contrôler automatiquement que chaque ligne respecte certaines règles.

L'idée était simple : s'assurer que les données soient cohérentes avant de les exploiter. Par exemple, vérifier qu'une date soit bien au bon format, qu'une valeur foncière soit positive, ou encore qu'un type de bien appartienne à une liste définie.

Concrètement, nous avons créé un modèle **Pydantic** qui décrit la structure attendue d'une ligne de données. Ce modèle sert ensuite à vérifier chaque enregistrement des fichiers DVF (Demandes de Valeurs Foncières), c'est-à-dire les bases publiques de l'État recensant l'ensemble des transactions immobilières en France depuis 2014.

Si une valeur ne correspond pas au format prévu, elle est automatiquement signalée, ce qui nous permet d'identifier rapidement les erreurs.

Mais maintenant quelles sont les nombreuses erreurs rencontrées et comment avons-nous réussi à mettre en place ce modèle ?

Comme vous le pensez, la mise en place de ce système n'a pas été simple !

Nous avons d'abord défini des contraintes assez strictes, mais cela a posé problème : beaucoup de lignes étaient rejetées pour des raisons mineures, comme une variation dans le format de date ou une majuscule manquante. Nous avons donc dû adapter notre modèle pour trouver un équilibre entre rigueur et tolérance.

Nous avons aussi rencontré des difficultés avec les tests unitaires et le pipeline GitLab, qui échouent parfois à cause de ces validations trop sensibles. Cela nous a forcés à revoir la logique du code et à simplifier certaines règles pour garantir que la validation reste fiable sans bloquer le reste du projet.

Finalement, nous avons choisi de ne pas exécuter la validation automatiquement à chaque pipeline, car nos données restent stables et ne proviennent pas d'un scraping régulier. Inutile donc de relancer les vérifications à chaque fois.

En revanche, nous pouvons lancer la validation manuellement quand c'est nécessaire, par exemple avant une mise à jour importante, afin de nous assurer que les données restent cohérentes et conformes aux attentes du modèle.

Même si la validation n'est pas effectuée automatiquement, elle reste une étape essentielle dans notre démarche de qualité. Nous la voyons comme un élément évolutif du projet, appelé à s'améliorer au fil du temps.


Notre objectif est de renforcer progressivement les règles de contrôle, pour affiner la précision du modèle et garantir que la base de données reste toujours fiable.

C'est une manière pour nous d'assurer que nos analyses s'appuient sur des données solides et de montrer le sérieux de notre approche.

Analyse des données


1. Analyse exploratoire: Graphes des tendances

Figure 9 - évolution des prix immobiliers en Île-de-France



Une première lecture du graphique des tendances révèle une forte disparité entre Paris et les autres départements de la région. Cette différence s'explique par le niveau particulièrement élevé des prix immobiliers dans la capitale, nettement supérieur à celui observé ailleurs en Île-de-France.

L'observation des graphiques d'évolution, département par département, met en évidence les spécificités locales du marché:



Les Hauts-de-Seine se positionnent comme le deuxième département le plus cher en matière de prix immobilier, tandis que la Seine-Saint-Denis affiche les tarifs les plus bas de la région. Entre 2021 et 2022, les deux départements ont connu une hausse des prix, marquée par un pic particulièrement prononcé en Seine-Saint-Denis. Toutefois, cette tendance s'est inversée dès l'année suivante, avec une baisse observable des prix.

Modélisation et prédictions

Sélection ou transformation des variables

Rappel des variables gardées après nettoyage et validation : [Dictionnaire des variables](#)

Après exploration des données, nous procédons à un dernier filtrage et ajustement des données pour l'entraînement de modèles prédictifs (voir [Data flow diagram](#)).

- Dans un premier temps nous retirons toutes les décimales inutiles (ex: 100,00 -> 100).
- Étant dans l'impossibilité d'identifier les propriétés précisément d'une année à l'autre, nous avons décidé de garder que l'année de la mutation comme variable catégorique additionnelle.
- La nature de mutation étant largement dominée par les ventes, nous décidons de ne garder que les ventes.
- Et par souci de redondance nous retirons les variables Code type local et Code commune pour ne garder que leurs versions nominatives.

Libellé originel	Descriptif	Nouveau nom dans notre base de données
Valeur foncière	Montant de l'évaluation déclaré(e) dans le cadre d'une mutation à titre onéreux.	property_value
Année	2021, 2022, 2023, ou 2024	year
Code postal	Référence cadastrale de la parcelle.	postal_code
Code département	Référence cadastrale de la parcelle.	department_code
Commune	Référence cadastrale de la parcelle.	town
Type local	maison, appartement, dépendance, local	property_type
Surface réelle bâtie	La surface réelle est la surface mesurée au sol entre les murs ou séparations.	building_area
Nombre pièces principales	Les cuisines, salles d'eau et dépendances ne sont pas prises en compte.	main_rooms
Surface terrain	Contenance du terrain	land_area

Description des modèles utilisés

Deux familles de modèles complémentaires ont été testées pour la prédiction du prix immobilier :

1. Régressions linéaires régularisées : Ridge et Lasso

Les modèles linéaires constituent une base indispensable pour la comparaison.

La régularisation Ridge (L2) stabilise les coefficients lorsqu'il existe des corrélations fortes entre variables (ex : surface et nombre de pièces).

La régularisation Lasso (L1) ajoute en plus une sélection automatique des variables en annulant certains coefficients.

Ces deux modèles permettent d'obtenir un premier repère robuste : s'ils échouent à expliquer correctement la cible, il faut envisager des modèles plus flexibles.

2. Random Forest Regressor

Le modèle Random Forest a été retenu pour capturer la réalité du marché immobilier, qui présente des relations non linéaires et de fortes disparités territoriales.

Il gère naturellement les interactions entre variables, tolère les distributions atypiques et permet d'identifier les facteurs ayant le plus d'impact sur le prix via l'analyse de l'importance des variables.

Ce modèle est également moins sensible au bruit ou aux valeurs extrêmes, ce qui le rend adapté aux données réelles issues des transactions immobilières.

Méthodes d'évaluation et résultats

Les jeux de données 2021 ont été divisés en deux ensembles :

- 70 % pour l'apprentissage
- 30 % pour la validation
avec un `random_state=42` garantissant la reproductibilité de la découpe.

Trois métriques complémentaires ont été utilisées :

- **MAE** : erreur moyenne (en euros), facilement interprétable
- **RMSE** : pénalise plus fortement les grosses erreurs
- **R²** : part de variance expliquée par le modèle

Tableau 1 - Comparaison des performances des modèles Ridge/Lasso/Random Forest


Modèle	MAE (€)	RMSE (€)	R ²
Ridge	15,6 M	72,1 M	0,32
Lasso	15,0 M	72,1 M	0,32
Random Forest	3,7 M	29,6 M	0,89

La Random Forest surpasse largement les modèles linéaires. Elle explique près de 90 % de la variabilité des valeurs foncières observées.

Cette rapide comparaison confirme que le marché immobilier ne suit pas une relation linéaire simple.

Les interactions entre localisation, surface et caractéristiques du bien jouent un rôle déterminant.

Figure 10 - Random forest sur les variables



Ce graphique présente les variables qui contribuent le plus aux prédictions du modèle Random Forest. On observe que la surface habitable (`building_area`) et le nombre de pièces sont les facteurs les plus déterminants : plus un logement est grand et bien configuré, plus son prix augmente. La surface du terrain joue également un rôle, en particulier dans les zones rurales où l'espace extérieur valorise davantage les propriétés. Enfin, les variables géographiques (code postal, commune, département) confirment l'importance capitale de l'emplacement : à caractéristiques équivalentes, la localisation peut fortement influencer la valeur du bien. Ce graphique aide ainsi à mieux comprendre le comportement du modèle et à vérifier que les résultats obtenus sont cohérents avec la réalité du marché immobilier.

Modèle retenu — Version 1

À l'issue de cette phase d'évaluation, le Random Forest Regressor s'impose comme la solution la plus performante pour la prédiction des prix immobiliers. Ce modèle offre un niveau de précision nettement supérieur aux approches linéaires, tout en demeurant robuste face à l'hétérogénéité des biens et aux fortes disparités territoriales observées sur le marché français. De plus, il présente un atout essentiel : sa capacité à fournir une interprétation claire de l'importance des variables, permettant d'expliquer les mécanismes qui influencent le prix d'un bien.

Les modèles linéaires régularisés (Ridge et Lasso) conservent néanmoins leur pertinence en tant que références de comparaison et constituent un outil d'analyse complémentaire lorsque l'objectif est de comprendre directement l'impact individuel de certaines variables sur le prix.

Ainsi, pour la livraison opérationnelle du Sprint 2, le modèle Random Forest a été retenu comme modèle de référence pour alimenter la fonctionnalité de prédiction immobilière.

Limites et axes d'amélioration

Le modèle a été entraîné uniquement sur les données de l'année 2021, ce qui peut limiter sa capacité à refléter l'évolution récente du marché (hausse des taux d'intérêt, ralentissement des ventes depuis 2023).

Par ailleurs, certains biais géographiques peuvent subsister : certaines zones sont largement représentées dans les données, tandis que d'autres ne le sont que marginalement. Des travaux ultérieurs intégreront donc plusieurs années d'historique et un rééquilibrage géographique pour améliorer la généralisation.

Ajout de nouveaux modèles : Gradient Boosting et Decision Tree

Dans la continuité du travail mené lors du Sprint 2, deux modèles supplémentaires ont été intégrés à la phase de modélisation : le Gradient Boosting Regressor et le Decision Tree Regressor.

Ces ajouts visent à approfondir la comparaison des approches et à explorer des modèles susceptibles d'améliorer la précision des prédictions ou la compréhension des mécanismes sous-jacents à la formation des prix immobiliers.

Le Decision Tree Regressor constitue la base des méthodes d'ensemble. Son principe repose sur la création d'un arbre hiérarchique divisant l'espace des variables en sous-ensembles homogènes selon des critères de minimisation d'erreurs. Chaque branche correspond à une règle de décision explicite fondée sur les caractéristiques d'un bien (surface, nombre de pièces, localisation, etc.). Ce modèle offre une lecture intuitive des décisions, mais il demeure sensible au surapprentissage : entraîné seul, il a tendance à mémoriser les spécificités de l'échantillon d'apprentissage, ce qui peut limiter sa capacité de généralisation. Dans notre étude, son coefficient de détermination atteint $R^2 = 0,809$, confirmant une bonne aptitude à expliquer la variabilité des prix, mais légèrement inférieure à celle de la Random Forest.

Le Gradient Boosting Regressor, de son côté, adopte une approche séquentielle : plusieurs arbres sont construits de manière itérative, chaque nouvel arbre cherchant à corriger les erreurs résiduelles des précédents.

Ce processus de « boosting » confère au modèle une capacité remarquable à capturer les interactions complexes entre variables, tout en limitant le biais et la variance.

Dans le cadre de ce projet, le Gradient Boosting a obtenu $R^2 = 0,811$, ce qui le place parmi les meilleurs modèles testés.

Il affiche toutefois un temps de calcul plus long et une interprétation plus technique, deux aspects qui doivent être pris en compte pour une intégration opérationnelle dans un environnement applicatif.


Résultats comparatifs des modèles

L'évaluation des performances a été conduite à l'aide des trois métriques précédemment définies : l'erreur absolue moyenne (MAE), la racine de l'erreur quadratique moyenne (RMSE) et le coefficient de détermination (R^2).

Le tableau ci-dessous synthétise les résultats obtenus pour l'ensemble des modèles testés :

Tableau 2 - Comparaison des modèles Gradient Boosting et Decision Tree

Modèle	MAE (€)	RMSE (€)	R^2
Random Forest	$3,75 \times 10^7$	$2,96 \times 10^8$	0,885
Gradient Boosting	$8,80 \times 10^7$	$3,79 \times 10^8$	0,811
Decision Tree	$3,78 \times 10^7$	$3,81 \times 10^8$	0,809
Lasso	$1,56 \times 10^8$	$7,21 \times 10^8$	0,316
Ridge	$1,56 \times 10^8$	$7,22 \times 10^8$	0,315



Le tableau de résultats et le graphique mettent clairement en évidence la supériorité des modèles d'ensemble sur les modèles linéaires. La Random Forest s'impose comme le modèle le plus performant, expliquant près de 89 % de la variance totale des prix immobiliers.

Le Gradient Boosting se positionne juste derrière ($R^2 \approx 0,81$) et se distingue par sa capacité à affiner la correction des erreurs tout en maîtrisant le compromis entre biais et variance.


Le Decision Tree, plus simple mais plus explicatif, offre quant à lui un point de comparaison utile pour visualiser la logique des décisions internes au modèle.

À l'inverse, les modèles Ridge et Lasso, bien adaptés à l'analyse des relations linéaires, montrent leurs limites face à la complexité du marché immobilier français, où les interactions entre variables structurelles et géographiques sont fortement non linéaires.

Ainsi, la Random Forest est retenue comme modèle de référence pour la version actuelle du projet, en raison de sa précision, de sa stabilité et de sa robustesse face à l'hétérogénéité du marché.

Pour mieux comprendre le comportement du modèle, on a mené une analyse SHAP détaillée. Les résultats confirment des intuitions bien connues des professionnels de l'immobilier : la surface du terrain et la surface habitable figurent parmi les variables les plus déterminantes, tout comme le type de bien (maison ou appartement). Les départements 75, 92 et 77 se démarquent nettement, traduisant l'importance des micro-marchés locaux. L'analyse SHAP fournit également des explications locales très instructives.

Graphiques : Importance SHAP (global et summary plot)



L'ordre des variables, dans sa globalité, correspond bien à une compréhension intuitive du marché immobilier : localisation > typologie > surfaces > temporalité.

Explication locale : analyse d'une prédiction individuelle

Le graphique SHAP individuel (force plot) montre concrètement comment le modèle parvient à une estimation, ici environ 4,15 M€. En observant la prédiction d'un bien individuel, on peut visualiser précisément quelles variables tirent le prix vers le haut ou vers le bas, ce qui rend le modèle beaucoup plus transparent.




Les facteurs qui tirent le prix vers le haut sont principalement : la typologie Maison, des surfaces généreuses et certains codes postaux valorisés.

À l'inverse, le modèle ajuste à la baisse l'estimation lorsque l'observation ne correspond pas à des zones habituellement très chères.


Cette explication montre que le modèle "raisonne" d'une manière très cohérente avec le fonctionnement réel du marché.

Analyse des erreurs

L'analyse des erreurs permet de mieux cerner les limites actuelles du modèle. Les résidus se concentrent principalement autour de zéro, ce qui montre qu'il n'existe pas de biais systématique. Les plus grosses erreurs concernent les biens atypiques, très haut de gamme ou situés dans des zones où la volatilité des prix est particulièrement élevée. Paris (75) et les Hauts-de-Seine (92) sont ainsi les départements où les erreurs moyennes restent les plus fortes, tandis que la grande couronne présente des performances nettement plus homogènes. Les petites surfaces, souvent soumises à une forte variabilité du prix au mètre carré, génèrent également davantage d'erreurs relatives. En revanche, les biens entre 90 et 150 m² offrent les prédictions les plus stables.



L'histogramme des résidus révèle une distribution globalement centrée, mais avec une queue étirée vers les valeurs extrêmes, caractéristique des biens atypiques ou très haut de gamme.



Le tableau statistique confirme cette dispersion : écart-type très élevé ($>900\,000$ €), résidus extrêmes pouvant atteindre ± 18 M€, médiane des erreurs autour de $69\,000$ €, ce qui montre une bonne performance générale.

Les erreurs par département mettent en évidence des zones difficiles :

Département	MAE (€)
77	117 736
95	158 657
91	187 314
78	215 910
93	285 879
94	315 896
92	653 525
75	1 617 344

Les erreurs en pourcentage par tranche de surface confirment que les très petites surfaces perturbent les ratios et les grandes surfaces manquent de représentativité.

Prochaines étapes de la modélisation

Les prochaines étapes incluront l'enrichissement des données, l'intégration de modèles plus avancés et l'adaptation du pipeline aux spécificités des segments de marché les plus complexes.

Déroulement des sprints

Sprint 1

Le projet a débuté par une réflexion sur les **objectifs individuels** de chaque membre, afin d'assigner les rôles et les tâches de manière cohérente avec les compétences et attentes de chacun.

La communication s'effectue principalement via Discord ou en présentiel, avec des réunions hebdomadaires et un suivi individuel assuré par le Scrum Master.

Ce premier sprint a été consacré à la **conception du produit et à la planification du projet**. L'équipe a identifié un besoin concret, collecté des idées de fonctionnalités, et élaboré une première version de la roadmap et un backlog (voir [Annexe](#)) en pensant à la **scalabilité** de l'application.

À l'issue de ce Sprint 1, nous considérons les fondations organisationnelles et techniques du projet satisfaisantes. Nous nous pencherons en priorité lors du Sprint 2 sur les analyses exploratoires des données, visualisations et modélisations.

Feedback Sprint 1

Points positifs :

- utilisation de données officielles open data (=data.gouv, INSEE...)

Points négatifs :

- nous aurions dû faire un premier modèle naïf pour avoir un vrai livrable utilisable
- manque de clarté sur la variable cible, penser à faire une slide uniquement pour elle
- revoir la présentation des données dans l'ensemble
- abandon des features login et historique (trop complexe et hors-sujet)
- attention à la valeur perçue lors d'une démo client

Conclusion : Se concentrer sur nos 2 pages principales : Dashboard et Prédiction.

Sprint 2

Ce deuxième sprint a eu lieu pendant la pause pédagogique de la Toussaint et le cumul de plusieurs rendus à la rentrée, ce qui a été perturbant pour les disponibilités et l'organisation de réunions.

Nous avons d'abord commencé par renouveler notre roadmap et logigramme, et commencé dès le début à réfléchir pour la présentation, notamment autour de la valeur perçue et la visualisation des données.

Similairement au premier sprint, chaque membre a pu travailler individuellement sur sa branche sur des features découpées de manière à faciliter la fusion du travail de tous.

Le sprint 3 se concentrera principalement sur l'amélioration des fonctionnalités existantes en termes de performances ou d'options de visualisation.

Feedback Sprint 2

Points positifs :

- bonne documentation, présentation, et structure du git
- bonne définition des objectifs

Points négatifs :

- manque d'une bonne phrase d'accroche pour vendre le produit
- tests unitaires non harmonisés
- manque de détails sur le contexte économique
- présentation de la roadmap difficile
- bugs visuels sur l'application

Conclusion : Continuer à ajouter les features importantes, revoir la présentation du produit/contexte, harmoniser le code.

Sprint 3

Pour ce sprint 3, l'équipe s'est d'abord réunie très tôt pour faire une rétrospective des deux derniers sprints, notamment pour identifier des possibles améliorations dans la communication ou la collaboration.

Par manque de communication lors du sprint 2, les tâches assignées étaient trop vagues et beaucoup de code/travail s'est avéré inutile, en plus d'avoir été partagé (push) d'un seul coup et trop tard pour faire des review de codes ou encore nettoyer correctement le dépôt GitLab.

Nous en avons profité pour aussi faire le point sur toute notre chaîne du traitement de données, l'architecture en médaillon, optimisation du formulaire, et l'intégration de routes FastAPI et la transition des csv vers SQLite.

Feedback Sprint 3

Environnement de développement et choix techniques

Nous avons visé à construire un environnement de travail structuré et facilement reproductible et fait des choix techniques visant à développer une application scalable pour faciliter toute évolution du projet.

Dépôt **GitLab** :

- Assignment des rôles Gestionnaire et Développeurs (Maintainer/Developer)
- Protection de la branche main
- Workflow en Merge Requests
- Pipeline CI/CD pour automatiser les contrôles de qualité et les tests
- Architecture des données en médaillons et organisation du dépôt

Autres outils :

- [Mermaid](#) pour la documentation graphique
- [pdoc](#) pour une API documentation du code
- [Python 3.13](#) sur [Visual Studio Code](#)
- Gestion des dépendances via [uv](#)
- Conteneurisation avec [Docker](#) (et .devcontainer)
- Développement de l'interface utilisateur avec [Gradio](#)
- Hébergement en ligne sur [Render.com](#) pour utilisation immédiate sans installation.
- Utilisation de SQLAlchemy pour assurer portabilité et scalabilité entre différents moteurs de base de données (SQLite, MySQL, PostgreSQL).

Conclusion


[Voir Sprint 2](#)

Bibliographie / Références / Liens


1. Le site
<https://gpd-m2sep-france-property-insight.onrender.com/>
2. Lien GitLab
<https://gitlab-mi.univ-reims.fr/phan0005/gpd-m2sep-france-property-insight>
3. Jeu de données
<https://www.data.gouv.fr/datasets/demandes-de-valeurs-foncieres/>
4. Étude du contexte immobilier
<https://edito.meilleursagents.com/locaux-pros/points-marche/marche-immobilier>
5. Outil pour l'interface utilisateur
<https://www.gradio.app/>
6. Pour l'hébergement de l'application en ligne
<https://render.com/>
7. Outil de documentation graphique
<https://www.mermaidchart.com/>
8. Pour une API documentation du code
<https://pdoc.dev/>
9. Logo FPI : France Property Insight
<https://www.vecteezy.com/vector-art/>
10. Tufféry, S. (2017). *Data mining et statistique décisionnelle: L'intelligence des données*. Dunod.

Annexes

Roadmap V1 [Retour Sprint 1](#)




Logigramme V1



Roadmap V2



Logigramme V2




Roadmap V3

FPI Roadmap 3

	23 octobre	6 novembre	20 novembre	4 décembre	18 décembre
Interface utilisateur	Structure des pages Web	Formulaire de prédiction de la valeur foncière d'une propriété Tableau de bord : Visualisation des variables clés	Saisie avec liste déroulante et Options de filtrage : inclusif, exclusif, réinitialisation	Intégration Dashboard Power BI Création de rapport	Carte interactive de la France
Data pipelines	Trouver des données fiables qui correspondent à nos objectifs	Validation des données via Pydantic Nettoyage des valeurs manquantes, aberrantes et des doublons	Routes FastAPI pour les saisies utilisateur et sorties programme	Migration de la base de donnée vers SQLite / MySQL	Insertion de données en masse Intégrer les données de toute la France
Algorithmes de prédiction	Statistique descriptive des variables clés	Modèles linéaires : Prédiction de valeur foncière	Implémentation d'autres modèles : DecisionTree, RandomForest, GradientBoosting	Cross Validation (K-fold) Sélection du meilleur modèle	Optimisation, Simplification et limites du modèle final

Logigramme V3



Metadata - Demandes de valeurs foncières

[Retour au Dictionnaire des variables](#)

Notice descriptive des fichiers « Demande de valeurs foncières »

En application de l'article 13 de la loi n° 2018-727 du 10 août 2018 pour un État au service d'une société de confiance (ESSOC) et du décret n° 2018-1350 du 28 décembre 2018 relatif à la publication sous forme électronique des informations portant sur les valeurs foncières déclarées à l'occasion des mutations immobilières, la Direction générale des Finances publiques (DGFIP) rend librement accessibles au public, sur le site data.gouv.fr, les éléments d'information qu'elle détient au sujet des valeurs foncières déclarées à l'occasion des mutations à titre onéreux intervenues au cours des cinq dernières années.

Les informations diffusées comprennent sur le site data.gouv.fr :

- des fichiers annuels de restitution des mutations à titre onéreux (vente, échange, expropriation ou adjudication) intervenues au cours des cinq dernières années (transmission des données sur 10 semestres au moment de la publication du mois d'avril, et sur 11 semestres en octobre – cf infra § 3.) ;
- la présente notice descriptive des fichiers ;
- un tableur contenant les tables de références associées aux natures de cultures pour les biens non bâtis (2 tables) ;
- les conditions générales d'utilisation (CGU) des données mises en ligne ;
- l'information des personnes concernées par le traitement informatique mis en œuvre.

1. L'origine des données

Les informations mises à disposition sont issues du traitement informatisé « Demande de valeurs foncières » alimenté par la « Base nationale des données patrimoniales » (BNDP).

L'application BNDP, qui recense les données patrimoniales contenues dans les documents déposés par les redevables ou leurs représentants dans les services en charge de la publicité foncière et de l'enregistrement, est alimentée par les traitements informatisés de l'administration fiscale relatifs à la documentation cadastrale (traitement « Majic ») et à la publicité foncière (traitement « Fidji »).

Les informations figurant dans chaque fichier sont donc issues du système d'information de la DGFIP, après publication des actes par le service de la publicité foncière, et complément des éléments cadastraux (référence cadastrale, nature des biens et descriptif des biens).

Important : le descriptif des biens de l'acte notarié n'est pas repris dans le fichier, à l'exception de la surface Carrez lorsque celle-ci est mentionnée.

NB : le contenu des fichiers dépend donc des informations qui auront été dûment publiées par le service de la publicité foncière.

2. Le périmètre géographique

Les informations diffusées sont issues des mutations publiées dans les services de la publicité foncière de l'ensemble du territoire de la France métropolitaine, à l'exception des départements du Bas-Rhin, du Haut-Rhin et de Moselle – les données les concernant relèvent du « livre foncier » et ne sont pas mobilisées dans la base nationale des documents patrimoniaux (BNDP) –, ainsi que des départements et régions d'outre-mer, excepté Mayotte.

3. La mise à jour des données

En application du décret du 28 décembre 2018, les informations communiquées font l'objet d'une mise à jour semestrielle.

Chaque année, une première diffusion sera effectuée en avril, présentant les mutations intervenues au cours des cinq dernières années et ayant fait l'objet d'une publication par un service de publicité foncière avant le 31 décembre de l'année précédente. La diffusion du mois d'avril concerne en conséquence cinq millésimes soit 10 semestres.

Une seconde diffusion sera effectuée en octobre portant sur les mutations intervenues au cours des cinq dernières années et ayant fait l'objet d'une publication par un service de publicité foncière avant le **30 juin de l'année en cours**.

L'attention est appelée sur le fait qu'en avril comme en octobre, compte tenu des publications effectuées au cours du dernier semestre pouvant porter sur des mutations intervenues lors de semestres précédents, l'ensemble des fichiers annuels sont actualisés.

4. L'identification des mutations à titre onéreux d'immeubles

Dans le cas des actes comprenant plusieurs mutations – appelées « dispositions » –, chacune d'entre elles est identifiée dans les fichiers par un numéro de disposition :

N° disposition
2

Dans le cas d'un document comportant des mutations distinctes, il y aura un numéro de disposition pour chaque mutation.

Attention : seules les dispositions qui concernent les mutations à titre onéreux sont restituées. Il est donc possible qu'une disposition n'apparaisse pas dans le fichier car elle a été écartée. Exemple : si un même document contient à la fois un état descriptif de division et deux ventes immobilières, seuls les numéros de disposition concernant les ventes seront restitués.

Notions de lots et de locaux pour les propriétés bâties :

Les lots, notion juridique immobilière, sont définis dans un état descriptif de division (EDD) et dans les documents de mutation. Ils permettent d'identifier une partie d'un immeuble et ainsi d'y associer un droit de propriété spécifique (propriété, usufruit, etc.).

En revanche, les locaux, notion fiscale, identifient les mêmes parties d'un immeuble pour les besoins de la taxe foncière et de la taxe d'habitation en regroupant plusieurs lots.

La correspondance entre le découpage en lots et en locaux n'est pas retracée.

Quand une disposition comporte plusieurs locaux ou plusieurs natures de culture, le fichier de restitution comporte autant de lignes qu'il y a de locaux ou de nature de culture concernés par la mutation.

Ainsi, pour une même publication, il peut y avoir 1 à n ligne(s) de restitution. Les données génériques (ainsi que le prix) sont alors répétées sur chaque ligne.

Cas particulier : dans le cas où n locaux sont construits sur un terrain comportant p natures de cultures différentes, le fichier de restitution comportera (n x p) lignes. En effet, dans ce cas, il n'est pas possible de ventiler automatiquement les locaux par nature de culture, alors le fichier présente toutes les combinaisons possibles.

Par exemple, si 2 locaux L1 et L2 sont construits sur une parcelle comportant 2 natures de culture N1 et N2 (sol et jardin), alors il y aura 4 lignes :

- L1 – N1
- L2 – N2
- L1 – N2
- L2 – N1

5. La structuration des fichiers de restitution

Les fichiers de restitution des valeurs foncières sont organisés de la manière suivante :

- identification de chaque mutation par son numéro de disposition ;
- affichage d'une ligne par local ;
- pour chaque local (chaque ligne), les lots de l'immeuble correspondant (dans la limite de 5) sont affichés ainsi que le nombre total de lots pour cet immeuble ;
- la surface réelle est associée au local ;
- restitution de la surface CARREZ associée au lot lorsqu'elle est indiquée.

6. La liste des données

La liste des données DVF respecte strictement les variables prévues par le décret du 28 décembre 2018. Aucune donnée supplémentaire ne peut à ce stade être transmise.

Colonne	Libellé	Descriptif	Origine de l'information
1	Code service CH	Données non restituées en application du décret n° 2018-1350 du 28 décembre 2018	Document (acte)
2	Référence document		
3	Article CGI 1		
4	Article CGI 2		
5	Article CGI 3		
6	Article CGI 4		
7	Article CGI 5		
8	N°de disposition	Dans le cas des actes comprenant plusieurs mutations – appelées « dispositions » –, chacune d'entre elles est identifiée dans les fichiers par un numéro de disposition. Seules les dispositions concernant les mutations à titre onéreux sont restituées dans le fichier.	
9	Date de mutation	Date de signature de l'acte (au format JJ/MM/AAAA) – Une restitution au format AAAA/MM/JJ (norme ISO 8601) est prévue à compter de la mise à jour d'octobre 2019.	
10	Nature de la mutation	Vente, vente en l'état futur d'achèvement, vente de terrain à bâtir, adjudication, expropriation ou échange	

Colonne	Libellé	Descriptif	Origine de l'information
11	Valeur foncière	Il s'agit du montant ou de l'évaluation déclaré(e) dans le cadre d'une mutation à titre onéreux. La valeur foncière : • inclut : • les frais d'agence, s'ils sont à la charge du vendeur. • l'éventuelle TVA. • exclut : • les frais d'agence, s'ils sont à la charge de l'acquéreur. • les frais de notaires. • la valeur des biens meubles stipulée dans l'acte de mutation.	Données cadastrales
12	N° de voie	Numéro dans la voie	
13	B/T/Q	Indice de répétition	
14	Type de voie	Exemple : Rue, avenue, etc.	
15	Code voie	Code Rivoli (répertoire informatisé codifiant, par commune, les voies, les lieux-dits et les ensembles immobiliers)	
16	Voie	Libellé de la voie	
17	Code postal		
18	Commune	Libellé de la commune	
19	Code département	Référence cadastrale de la parcelle	
20	Code commune		

Colonne	Libellé	Descriptif	Origine de l'information
21	Préfixe de section		
22	Section		
23	N° de plan		
24	N° de volume		Document (acte)
25	1er lot	Un lot de copropriété est constitué d'une partie privative (appartement, cave, etc.) et d'une quote-part de partie commune (tantièmes). Seuls les 5 premiers lots sont mentionnés. Si le nombre de lots est supérieur à 5, ils ne sont pas restitués.	Document (acte)
26	Surface Carrez du 1er lot		
27	2e lot		
28	Surface Carrez du 2e lot		
29	3e lot		
30	Surface Carrez du 3e lot		
31	4e lot		
32	Surface Carrez du 4e lot		
33	5e lot		
34	Surface Carrez du 5e lot		
35	Nombre de lots	Nombre total de lots par disposition.	Document (acte)
36	Code type local	1 : maison ; 2 : appartement ; 3 : dépendance (isolée) ; 4 : local industriel et commercial ou assimilés	Données cadastrales
37	Type local		

Colonne	Libellé	Descriptif	Origine de l'information
38	Identifiant local	<i>Donnée non restituée en application du décret n° 2018-1350 du 28 décembre 2018</i>	
39	Surface réelle bâti	La surface réelle est la surface mesurée au sol entre les murs ou séparations et arrondie au mètre carré inférieur. Les surfaces des dépendances ne sont pas prises en compte.	
40	Nombre de pièces principales	Les cuisines, salles d'eau et dépendances ne sont pas prises en compte.	
41	Code nature culture	Voir dans le présente document la table de références « nature de culture »	
42	Nature culture spéciale	Voir dans le présent document la table de références « nature de culture spéciale »	
43	Surface terrain	Contenance du terrain	

Lexique immobilier DGFIP

Nature et valeur de la mutation

- **Disposition** : une disposition constitue une unité d'analyse juridique. Un document peut en comporter plusieurs, mais seules celles concernant les mutations à titre onéreux sont restituées. Ainsi, une vente simple est représentée par une seule disposition rattachée à un prix (cf : valeur foncière) pour laquelle sont identifiés les rôles et les droits détenus pour chacune des parties sur chaque immeuble. Un document comportant une vente ainsi qu'une division de parcelle contribue à la création de deux dispositions, l'une concernant la division et l'autre la vente car il s'agit de 2 unités d'analyse juridique distinctes.
- **Document ou acte** : entité retraçant un ou plusieurs événements juridiques et/ou fiscaux qui portent sur une ou plusieurs personnes et/ou un ou plusieurs biens. Un document est composé de une ou plusieurs dispositions.
- **Mutation à titre onéreux** : transfert de propriété moyennant une contrepartie.
- **Mutation immobilière** : transfert de la propriété d'un immeuble pouvant intervenir à titre onéreux (vente) ou gratuit (donation).
- **VEFA** : vente en état futur d'achèvement. Cette vente dite souvent 'sur plan' rend l'acquéreur propriétaire des sols, des constructions existantes et à venir jusqu'à achèvement de son bien.
- **Valeur foncière déclarée** : il s'agit du prix du ou des biens immobiliers déclarés dans le cadre d'une mutation à titre onéreux. À chaque disposition correspond un prix.

Localisation

- **Adresse** : élément de localisation géographique composé notamment d'une partie codifiée et d'une partie littérale.
- **Adresse codifiée** : adresse en France dont le département, la commune et la voie sont enregistrés sous la forme de codes Rivioli.
- **Adresse littérale** : adresse structurée non codifiée.
- **Code commune** : code INSEE de la commune sur 3 chiffres.

Références cadastrales

- **Parcelle** : portion de terrain d'un seul tenant, situé dans un même lieu-dit, appartenant à un même propriétaire ou à une même indivision et constituant une unité foncière indépendante selon l'agencement donné à la propriété. Le numérotage parcellaire est effectué, à l'origine, sans interruption et par sections. Toute parcelle nouvelle ou modifiée reçoit un nouveau numéro pris à la suite du dernier attribué dans la section ; le numéro de la parcelle primitive n'est jamais réutilisé mais il permet de localiser la nouvelle parcelle créée qui fait référence à la parcelle primitive.
- **Préfixe de section** : identifiant complémentaire utilisé pour différencier les immeubles dans le cadre des communes absorbées ou pour la gestion des

quartiers dans le cas de Marseille et Toulouse. Dans le premier cas, il s'agit de l'ancien code de la commune absorbée et dans le second cas, d'un identifiant propre.

- **Référence cadastrale** : identifiant national des immeubles. Il est composé des codes département, commune, du préfixe de section, de la section et du numéro de plan, suivis pour les volumes, d'un numéro de volume, et pour les lots, d'un numéro de lot éventuellement précédé d'un numéro de volume.
- **Section (ou section cadastrale)** : fraction du territoire communal déterminée de façon à faciliter l'établissement et la consultation des documents cadastraux. Son périmètre est constitué, dans la mesure du possible, par les limites naturelles présentant un caractère suffisant de fixité (voies de communication, cours d'eau, etc.). Une section correspond à un ou plusieurs lieux-dits en zone rurale et, en zone urbaine, à un ou plusieurs quartiers.
- **Subdivision fiscale** : partie d'une parcelle ayant même nature de culture ou affectation. Les subdivisions fiscales sont délimitées sur le plan par des tirets et désignées par des lettres minuscules distinctes (a, b, etc.). Les natures de cultures sont divisées en classes figurant dans les relevés de propriété de matrice cadastrale.
- **Volume** : division de l'espace située au-dessus ou au-dessous d'un terrain, décrite dans le cadre d'une division de la propriété en volumes (ex : tour de bureaux).

Descriptif du bien

- **Dépendance bâtie ordinaire** : toute construction accessoire au bâtiment principal sans communication intérieure avec celui-ci, située sur la même unité topographique et n'entrant pas dans la catégorie des dépendances de pur agrément. Il en résulte que les dépendances bâties ordinaires ne font pas l'objet d'une évaluation distincte (pour l'établissement de la taxe foncière) sauf les dépendances isolées. Pour les maisons individuelles, sont évalués en tant que dépendances bâties ordinaires rattachées à la partie principale les garages, caves, celliers, abris de jardin, distincts de la partie principale mais situés sur la même « propriété ».
- **Dépendance bâtie de pur agrément** : construction accessoire à la partie principale telle que piscine, jardin d'hiver extérieur, serre. Cette dépendance est nécessairement évaluée distinctement pour l'établissement de la taxe foncière.
- **Dépendance bâtie isolée** : construction accessoire à la partie principale mais ne faisant pas partie du même groupement topographique que le local qu'elle dessert (ex : garage séparé de l'habitation par une route ou chemin). Elle est évaluée distinctement pour l'établissement de la taxe foncière.
- **Lot** : un lot de copropriété est constitué d'une partie privative et d'une quote-part de parties communes
- **Pièce (nombre de pièces principales)** : espace partiellement ou entièrement cloisonné, destiné à être normalement utilisé pour y séjourner, y dormir ou prendre des repas. Ainsi, le type d'appartement (studio, T1, T2, etc.) est déterminé à partir du nombre de chambres et de salles à manger.

- **Surface « Carrez » (ou surface privative d'un lot de co-propriété) (loi du 18/12/1996) :** superficie des planchers des locaux clos et couverts après déduction des surfaces occupées par les murs, cloisons, marches et cages d'escalier, gaines, embrasures de portes et fenêtres, sans tenir compte des planchers des parties de locaux d'une hauteur inférieure à 1,80 m. Les lots et fractions de lots d'une superficie inférieure à 8 m² ne sont pas pris en compte non plus.
- **Surface réelle :** surface mesurée au sol entre murs ou séparations et arrondie au mètre carré inférieur. Doivent être comptabilisés les alcôves, les surfaces occupées par les appareils sanitaires, les cheminées, les éléments de décor, à l'exception des surfaces consacrées aux emmarchements et aux trémies d'escalier.
- **Surface terrain :** surface cadastrale du terrain.
- **Terrain à bâtir :** terrain qui, par sa situation (agglomération, lotissement) ou le cas échéant son aménagement (canalisation d'eau, d'électricité, de gaz, viabilité), ne peut normalement recevoir d'autre affectation que celle de sol de construction, ni être raisonnablement rangé dans un autre groupe de nature de culture, l'exploitation devant être suffisamment rémunératrice eu égard au capital investi. Mais outre la situation du terrain et son aménagement, le classement dans la catégorie des terrains à bâtir doit tenir compte de l'intention du propriétaire à l'égard de l'affectation de son terrain.

Table de références

Nature de culture

Code nature de culture	Libellé nature de culture
AB	terrains à bâtir
AG	terrains d'agrément
B	bois
BF	futaies feuillues
BM	futaies mixtes
BO	oseraies
BP	peupleraies
BR	futaies résineuses
BS	taillis sous futaie
BT	taillis simples
CA	carrières
CH	chemin de fer
E	eaux
J	jardins
L	landes
LB	landes boisées
P	prés
PA	pâtures
PC	pacages
PE	prés d'embouche

Code nature de culture	Libellé nature de culture
PH	herbages
PP	prés plantes
S	sols
T	terres
TP	terres plantées
VE	vergers
VI	vignes

Table de références Nature de culture spéciale
--

Code nature culture spéciale	Libellé nature culture spéciale
ABREU	Abreuvoirs
ABRIC	Abricotiers
ACACI	Acacias
AEROD	Aérodrome
AIRE	Aire ou airial
ALLEE	Allée (no groupe)
ALLUV	Alluvions
AMAND	Amandiers
ARDOI	Ardoisière
ARGIL	Argillère
ASPER	Aspergerie
AULN	Aulnaie
AVENU	Avenue
BALLA	Ballastière
BAMBO	Bambouseraie
BASS	Bassin
BIEF	Bief
BOUL	Boulaie
BROUS	Broussailles ou buissons

Code nature culture spéciale	Libellé nature culture spéciale
BRUY	Bruyère
BTIGE	Verger exploite en basses tiges
BUIS	Buissière
CAMP	Terrain de camping
CANAL	Canal
CASS	Cassis
CEDRA	Cédratiers
CERCL	Cercliere
CERIS	Cerisaie ou cerisiers
CHASS	Terrain de chasse
CHAT	Châtaigneraie
CHEM	Chemin (non groupe)
CHENE	Chênes
CHLIE	Chênes-lièges
CHTRU	Chênes - truffiers
CHVER	Chênes - verts
CIDRE	Cidre
CITRO	Citronniers
CLAIR	Clares
COING	Cognassiers
COULE	Bois de couleur
CRAY	Crayère

Code nature culture spéciale	Libellé nature culture spéciale
CRESS	Cressonnière
CRYPT	Cryptomeria
DIGUE	Digues
DUNE	Dunes
EAU	Pièce d'eau
ECOLE	École
EPICE	Épicéas
ESPAL	Verger exploite en espaliers
ETANG	Étangs
EUCAL	Eucalyptus
FALAI	Falaise
FAMIL	Familial (jardin)
FER	Chemin de fer
FILAO	Filao
FLOR	Jardin floral
FONT	Fontaine
FOSSE	Fosse
FOUG	Fougeraie
FRAMB	Framboisiers
FRICH	Friche
GAREN	Garenne
GENET	Genets

Code nature culture spéciale	Libellé nature culture spéciale
GLAIS	Glaisière
GRAVE	Gravière
HAIES	Haies fruitières
HERB	Herbage
HETRE	Hêtres
HIST	Dépendances de monument historique
HORT	Jardin horticole
HOUBL	Houblon
HTIGE	Verger exploite en hautes tiges
HUITR	Parc à huîtres
IMM	Dépendances d'ensemble immobilier
IMPRO	Lande improductive
INTEN	Verger industriel
JARD	Jardin d'agrément
JETT	Jettins
JOUAL	Joualle
KIWIS	Kiwis
LAC	Lac
LAGUN	Lagune
LAVOI	Lavoir
LEGUM	Légumière de plein champ

Code nature culture spéciale	Libellé nature culture spéciale
MAQUI	Maquis
MARAI	Pré marais
MARAM	Jardin maraîcher aménagé
MARE	Mare
MAREC	Marécage
MARN	Marnière
MARNA	Jardin maraîcher non aménagé
MELEZ	Mélèzes
MOTTE	Mottes
MUR	Muraies ou muriers (vergers)
NATUR	Bois naturel
NOISE	Noiseraie ou noisetiers
NOYER	Noyeraie ou noyers
NPECH	Etang non pêchable
OLIVE	Oliveraie ou oliviers
ORANG	Orangers (verger)
ORME	Ormaie ou ormes
PACAG	Pacage
PAFEU	Pare - feux
PALMI	Bois palmiste
PARC	Parc
PASS	Passage (no groupe)

Code nature culture spéciale	Libellé nature culture spéciale
PATIS	Patis
PATUR	Pâture plantée
PECH	Etangs pêchables
PECHE	Pêchers
PEPIN	Pépinières
PIEDS	Pieds - mères (vignes)
PIERR	Pierraille, pierrier
PIN	Pins
PLAGE	Plage
PLATR	Plâtrière
PLVEN	Vergers de plein vent
POIRE	Poiriers
POMME	Pommiers
POTAG	Jardin potager
PROTE	Bois de protection
PRUNE	Pruniers
RAIS	Raisin de table
RESER	Réservoir
RESIN	Résineux
RIVAG	Rivage (bois de)
RIZ	Rizière
ROC	Rocs ou rochers

Code nature culture spéciale	Libellé nature culture spéciale
ROUI	Routoir ou ruissoir
RUE	Rue
RUINE	Ruines
SABLE	Sablière
SALIN	Marais salant
SAPIN	Sapins ou sapinière
SART	Sartières
SAULE	Saulaie ou saussaie
SERRE	Serre
SOL	Sol
SOURC	Source
SPORT	Terrain de sport
TAMAR	Tamarin
TAUZ	Taillis tauzin
TERRI	Terrils
TOURB	Tourbière
TOUYA	Touyas
VADC	Vins d'appellation d'origine contrôlée
VAGUE	Terrain vague
VANIL	Vanille
VAOC	Vins d'appellation d'origine contrôlée

Code nature culture spéciale	Libellé nature culture spéciale
VCHAS	Chasselat
VDQS	Vins délimités de qualité supérieure
VIGNE	Vigne
VIVIE	Vivier